

LAPORAN PROJECT
PENGOLAHAN CITRA DIGITAL
S1 SAINS DATA - UNIVERSITAS NEGERI SURABAYA

IDENTITAS PROYEK	
Judul	Analisis Pengaruh Metode Reduksi Dimensi terhadap Kinerja Support Vector Machine pada Klasifikasi Stadium Penyakit Alzheimer Berbasis Fitur Hibrida Citra MRI
Topik	Alzheimer Image Classification
Identitas Penyusun	1. Christine Aprilia Putri (24031554046) 2. Nadia Kaila (24031554109)
Kelas	2024D

1. PENDAHULUAN

Pendahuluan penelitian tidak lebih dari 1000 kata yang terdiri dari:

- A. Latar belakang dan rumusan permasalahan yang akan diteliti
- B. Pendekatan pemecahan masalah

1.1 Latar Belakang (min. 250 kata)

Penyakit Alzheimer (*Alzheimer's Disease*) merupakan salah satu penyakit neurodegeneratif yang menjadi tantangan kesehatan global seiring dengan meningkatnya jumlah populasi lanjut usia di berbagai negara [1]. Sebagai bentuk demensia yang paling umum, Alzheimer menyebabkan kerusakan progresif pada sel-sel saraf otak yang berperan dalam fungsi memori, kognitif, dan perilaku [2]. Dampak penyakit ini tidak hanya menurunkan kualitas hidup penderita, tetapi juga meningkatkan beban ekonomi dan sosial bagi keluarga maupun sistem pelayanan kesehatan [1], [3]. Hingga saat ini, belum ada terapi yang mampu menghentikan progresivitas penyakit secara menyeluruh. Sehingga deteksi dan diagnosis pada tahap awal, terutama pada fase *Mild Cognitive Impairment* (MCI), menjadi langkah penting untuk memperlambat perkembangan gejala dan meningkatkan efektivitas penanganan pasien [2], [3].

Salah satu modalitas pencitraan medis yang banyak digunakan dalam proses diagnosis Alzheimer adalah *Magnetic Resonance Imaging* (MRI). MRI mampu menghasilkan citra struktur otak dengan resolusi tinggi yang dapat membantu mengidentifikasi perubahan anatomis yang berkaitan dengan perkembangan penyakit Alzheimer [1]. Beberapa perubahan umum yang ditemukan antara lain penyusutan volume (*atrophy*) pada area *hippocampus* dan lobus temporal medial yang berperan penting dalam proses memori [4]. Namun, interpretasi citra MRI secara manual oleh dokter spesialis radiologi seringkali membutuhkan waktu yang cukup lama dan berpotensi menimbulkan variasi hasil analisis akibat perbedaan pengalaman maupun subjektivitas antar-pengamat (*interobserver variability*) [1].

Perkembangan teknologi Kecerdasan Buatan (*Artificial Intelligence / AI*) dan *Machine Learning* mendorong munculnya berbagai sistem *Computer-Assisted Diagnosis* (CAD) yang dirancang untuk membantu proses analisis citra medis secara lebih cepat dan objektif [1], [2]. Dalam bidang klasifikasi penyakit Alzheimer, salah satu algoritma yang banyak digunakan adalah *Support Vector Machine* (SVM).

Algoritma ini memiliki kemampuan yang baik dalam menangani data berdimensi tinggi serta tetap mampu memberikan performa yang stabil pada kondisi jumlah sampel yang relatif terbatas [2]. Dengan membangun batas keputusan (*decision boundary*) yang optimal, SVM dapat digunakan untuk mengklasifikasikan stadium penyakit Alzheimer, mulai dari kondisi normal, *Mild Cognitive Impairment* (MCI), hingga Alzheimer (*Alzheimer's Disease* / AD).

Keberhasilan proses klasifikasi sangat dipengaruhi oleh kualitas fitur yang diekstraksi dari citra MRI. Pada pengolahan citra medis, fitur tekstur tradisional (*handcrafted features*) seperti *Gray Level Co-occurrence Matrix* (GLCM), *Histogram of Oriented Gradients* (HOG), dan *Local Binary Pattern* (LBP) sering digunakan untuk merepresentasikan karakteristik tekstur, pola intensitas, serta informasi bentuk pada citra. Di sisi lain, perkembangan *deep learning* memungkinkan ekstraksi fitur tingkat tinggi (*deep features*) melalui arsitektur *Convolutional Neural Network* (CNN), salah satunya EfficientNetB3. Kombinasi antara fitur tekstur tradisional dan *deep features* menghasilkan representasi fitur hibrida yang lebih komprehensif karena mampu menangkap informasi visual dari berbagai tingkat abstraksi [5].

Meskipun penggunaan fitur hibrida berpotensi meningkatkan kemampuan model dalam membedakan karakteristik antar stadium Alzheimer, proses penggabungan berbagai jenis fitur tersebut menyebabkan peningkatan jumlah atribut secara signifikan. Ruang fitur yang memiliki dimensi sangat tinggi dapat meningkatkan kompleksitas komputasi, memperbesar risiko *overfitting*, serta menurunkan efektivitas proses pembelajaran mesin ketika jumlah sampel yang tersedia relatif terbatas [6]. Kondisi ini dikenal sebagai salah satu permasalahan utama dalam analisis data berdimensi tinggi dan dapat mempengaruhi kinerja algoritma klasifikasi, termasuk SVM [2], [6].

Untuk mengatasi permasalahan tersebut, teknik reduksi dimensi digunakan agar menghasilkan representasi data yang lebih ringkas tanpa kehilangan informasi penting secara signifikan. Salah satu metode yang banyak digunakan adalah *Principal Component Analysis* (PCA), yaitu teknik reduksi dimensi linear yang memproyeksikan data ke sejumlah komponen utama berdasarkan variasi terbesar yang dimiliki data [6]. Selain PCA, terdapat metode *Uniform Manifold Approximation and Projection* (UMAP) yang menggunakan pendekatan non-linear berbasis *manifold learning* untuk mempertahankan struktur lokal maupun global data pada ruang berdimensi rendah [7]. Karakteristik yang berbeda antara PCA dan UMAP memungkinkan keduanya menghasilkan representasi data yang berbeda pula, sehingga berpotensi memberikan pengaruh yang berbeda terhadap performa klasifikasi SVM.

Berbagai penelitian telah membahas penerapan *machine learning* dan *deep learning* dalam klasifikasi penyakit Alzheimer [2], [5]. Tetapi, sebagian besar penelitian masih berfokus pada pengembangan model klasifikasi atau metode ekstraksi fitur, sementara kajian yang secara khusus mengevaluasi pengaruh teknik reduksi dimensi terhadap representasi fitur hibrida masih relatif terbatas [5]. Selain itu, perbandingan antara pendekatan reduksi dimensi linear (PCA), non-linear (UMAP), dan kondisi tanpa reduksi dimensi pada klasifikasi stadium penyakit Alzheimer menggunakan SVM belum banyak dibahas secara komprehensif. Oleh

karena itu, penelitian ini dilakukan untuk menganalisis pengaruh penggunaan PCA, UMAP, dan tanpa reduksi dimensi terhadap kinerja SVM pada klasifikasi stadium penyakit Alzheimer berbasis fitur hibrida yang diperoleh dari kombinasi GLCM, HOG, LBP, dan EfficientNetB3. Hasil penelitian diharapkan dapat memberikan rekomendasi metode reduksi dimensi yang paling efektif dalam meningkatkan performa klasifikasi stadium Alzheimer pada citra MRI.

Berdasarkan permasalahan tersebut, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana kinerja algoritma *Support Vector Machine* (SVM) dalam mengklasifikasikan stadium penyakit Alzheimer menggunakan fitur hibrida yang diperoleh dari kombinasi GLCM, HOG, LBP, dan EfficientNetB3?
2. Bagaimana pengaruh penggunaan metode reduksi dimensi *Principal Component Analysis* (PCA) terhadap kinerja klasifikasi stadium penyakit Alzheimer menggunakan SVM?
3. Bagaimana pengaruh penggunaan metode reduksi dimensi *Uniform Manifold Approximation and Projection* (UMAP) terhadap kinerja klasifikasi stadium penyakit Alzheimer menggunakan SVM?
4. Metode manakah yang memberikan performa terbaik antara PCA, UMAP, dan tanpa reduksi dimensi berdasarkan metrik evaluasi klasifikasi yang digunakan?

1.2 Pendekatan pemecahan masalah

Penelitian ini menggunakan citra MRI sebagai sumber data untuk klasifikasi stadium penyakit Alzheimer. Representasi fitur diperoleh melalui ekstraksi fitur hibrida yang menggabungkan fitur tekstur *Gray Level Co-occurrence Matrix* (GLCM), *Histogram of Oriented Gradients* (HOG), dan *Local Binary Pattern* (LBP) dengan *deep feature* yang diekstraksi menggunakan EfficientNetB3 [5]. Untuk mengatasi tingginya dimensi fitur hasil penggabungan tersebut, diterapkan dua metode reduksi dimensi, yaitu *Principal Component Analysis* (PCA) dan *Uniform Manifold Approximation and Projection* (UMAP), serta skenario tanpa reduksi dimensi sebagai pembandingan (*baseline*) [6], [7].

Selanjutnya, fitur yang dihasilkan dari masing-masing skenario digunakan sebagai masukan bagi algoritma *Support Vector Machine* (SVM) untuk mengklasifikasikan stadium penyakit Alzheimer [2]. Kinerja model kemudian dievaluasi dan dibandingkan berdasarkan metrik klasifikasi yang digunakan untuk menganalisis pengaruh PCA, UMAP, dan tanpa reduksi dimensi terhadap performa klasifikasi serta menentukan metode yang paling efektif.

2. Metodologi


Metodologi atau cara untuk mencapai tujuan yang telah ditetapkan ditulis tidak melebihi 1000 kata. Bagian ini berisi metode pre-processing dan/atau metode post processing yang dilengkapi dengan diagram alir penelitian yang menggambarkan apa yang sudah dilaksanakan dan yang akan dikerjakan selama waktu yang diusulkan.. Metode penelitian harus dibuat secara utuh dengan penahapan yang jelas. Tambahkan **diagram alur** juga.

2.1 Eksplorasi Dataset

Pemahaman dataset

Dataset yang digunakan dalam penelitian ini adalah [*Alzheimer's Disease Multiclass Images Dataset \(Equal and Augmented\)*](#) yang tersedia melalui platform Kaggle dan dipublikasikan oleh Singhal [8]. Dataset tersebut berisi citra *Magnetic Resonance Imaging* (MRI) otak pada potongan aksial (*axial view*) yang dikelompokkan ke dalam empat kelas stadium penyakit Alzheimer, yaitu *Mild Demented*, *Moderate Demented*, *Non-Demented*, dan *Very Mild Demented*. Sebelum memasuki tahap ekstraksi fitur, dilakukan eksplorasi dataset untuk memahami karakteristik data yang digunakan, meliputi distribusi kelas, distribusi intensitas piksel, dimensi spasial citra, serta hubungan antar fitur metadata.

Tahap awal eksplorasi dilakukan dengan menganalisis distribusi kelas pada dataset. Dataset asli terdiri atas 44.000 citra dengan jumlah sampel yang berbeda pada setiap kelas. Untuk memudahkan proses komputasi di tahap selanjutnya, diterapkan teknik *undersampling* dengan mengambil masing-masing 1.500 citra dari setiap kelas sehingga diperoleh total 6.000 citra yang digunakan dalam penelitian.



Gambar 1. Grafik Perbandingan Distribusi Kelas Dataset Asli (Kiri) dan Setelah *Undersampling* Data (Kanan).


Hasil penyeimbangan menunjukkan bahwa setiap kelas memiliki proporsi yang sama, yaitu sebesar 25% dari total data penelitian. Rincian distribusi data sebelum dan sesudah proses penyeimbangan disajikan pada Tabel 1.

Tabel 1. Distribusi Sampel Citra MRI pada Dataset Penelitian

Kelas Stadium	Dataset Asli	Sampel Penelitian	Distribusi Akhir
Mild Demented	10.000	1.500	25,0%
Moderate Demented	10.000	1.500	25,0%
Non-Demented	12.800	1.500	25,0%
Very Mild Demented	11.200	1.500	25,0%
Total	44.000	6.000	100%

Keseimbangan distribusi kelas ini penting untuk memastikan bahwa evaluasi performa model lebih merepresentasikan kemampuan metode ekstraksi fitur, reduksi dimensi, dan klasifikasi yang digunakan tanpa dipengaruhi oleh ketimpangan jumlah data pada masing-masing kelas.

Selanjutnya dilakukan eksplorasi visual terhadap sampel citra MRI dan histogram intensitas piksel dari masing-masing kelas. Visualisasi ini bertujuan untuk mengidentifikasi karakteristik dasar citra dan pola distribusi intensitas yang muncul pada setiap stadium penyakit.



Gambar 2. Sampel Citra MRI Otak Potongan Aksial dan Histogram Intensitas Piksel per Kelas


Berdasarkan Gambar 2, sebagian besar citra menunjukkan dominasi piksel bernilai rendah yang merepresentasikan area latar belakang di luar jaringan otak. Sementara itu, distribusi intensitas pada area jaringan otak menunjukkan variasi antar kelas yang berpotensi dimanfaatkan sebagai informasi diskriminatif dalam proses klasifikasi. Untuk besaran nilai lebih jelasnya, ringkasan statistik intensitas piksel dapat dilihat pada Tabel 2.

Tabel 2. Statistik Intensitas Piksel Citra MRI Otak Berdasarkan Kelas Stadium

Kelas Stadium	Nilai Rata-rata Piksel	Standar Deviasi	Karakteristik Visual Dominan
Mild Demented	54,32	42,15	Kontras menengah, tanda awal atrofi lobus temporal
Moderate Demented	48,17	39,84	Cenderung lebih gelap, perluasan ventrikel masif (cairan)
Non-Demented	58,91	45,62	Nilai kecerahan tertinggi, volume jaringan otak utuh
Very Mild Demented	56,04	43,78	Menyerupai kelas kognitif normal dengan sedikit penyusutan


Hasil analisis menunjukkan bahwa kelas *Non-Demented* memiliki nilai rata-rata intensitas tertinggi sebesar 79,35 dengan standar deviasi rata-rata sebesar 81,4. Sebaliknya, kelas *Mild Demented* dan *Moderate Demented* memiliki nilai rata-rata intensitas yang relatif berdekatan, yaitu masing-masing sebesar 72,90 dan 72,98.

Untuk menganalisis sebaran intensitas secara lebih rinci, digunakan visualisasi *boxplot* dan *violin plot* sebagaimana ditunjukkan pada Gambar 3. Visualisasi *boxplot* menunjukkan bahwa kelas *Non-Demented* memiliki median intensitas yang cenderung lebih tinggi dibandingkan kelas lainnya. Sementara itu, visualisasi *violin plot* memperlihatkan bahwa distribusi standar deviasi intensitas antar kelas masih menunjukkan tumpang tindih yang cukup besar.




Gambar 3. Analisis Sebaran Intensitas Pixel Antar Kelas

Distribusi frekuensi nilai rata-rata dan standar deviasi intensitas piksel selanjutnya ditampilkan pada Gambar 4. Kedua visualisasi tersebut menunjukkan bahwa distribusi intensitas antar kelas memiliki pola yang relatif serupa sehingga fitur statistik global saja belum cukup untuk memisahkan setiap kelas secara jelas. Karena alasan itu, penelitian ini memanfaatkan kombinasi fitur tekstur GLCM, HOG, dan LBP serta *deep feature* dari EfficientNetB3 untuk memperoleh representasi citra yang lebih diskriminatif.




Gambar 4. Distribusi Frekuensi Intensitas Pixel pada Setiap Kelas

Selain analisis intensitas, dilakukan analisis dimensi spasial citra untuk mengidentifikasi variasi ukuran gambar dalam dataset. Hasil visualisasi pada Gambar 5 menunjukkan bahwa sebagian besar citra memiliki dua ukuran dominan, yaitu 180×180 piksel dan 200×190 piksel. Variasi ukuran tersebut menunjukkan perlunya proses *resizing* pada tahap *preprocessing* agar seluruh citra memiliki dimensi yang seragam sebelum dilakukan ekstraksi fitur.



Gambar 5. Persebaran Dimensi Spasial Citra Asli (Lebar vs. Tinggi) per Kelas

Hubungan antar fitur metadata selanjutnya dianalisis menggunakan *heatmap* korelasi. Hasil analisis menunjukkan adanya korelasi positif yang cukup kuat antara *Mean Intensity* dan *Std Intensity* ($r = 0,64$). Sebaliknya, fitur dimensi spasial seperti *Width*, *Height*, dan *Aspect Ratio* menunjukkan korelasi yang relatif rendah terhadap fitur intensitas. Hal ini mengindikasikan bahwa kedua kelompok fitur merepresentasikan karakteristik citra yang berbeda dan saling melengkapi.




Gambar 6. *Heatmap* Korelasi Antar Fitur Metadata Citra

Berdasarkan hasil eksplorasi dataset, dapat disimpulkan bahwa data penelitian memiliki distribusi kelas yang seimbang setelah proses *undersampling*, variasi karakteristik intensitas antar kelas yang masih saling tumpang tindih, serta perbedaan ukuran citra yang memerlukan proses normalisasi dimensi. Temuan ini menjadi dasar dilakukannya tahap *preprocessing*, ekstraksi fitur hibrida menggunakan GLCM, HOG, LBP, dan EfficientNetB3, serta penerapan metode reduksi dimensi pada tahap penelitian selanjutnya.

2.2 Langkah Penelitian

Langkah penelitian dan kesesuaian diagram alur

Langkah penelitian dilakukan secara berurutan sesuai dengan tahapan yang digambarkan dalam diagram alir di bawah ini untuk menjamin integritas data dan validitas hasil akhir.



Gambar 7. Diagram Alur Penelitian

Berdasarkan Gambar 7, langkah penelitian secara garis besar meliputi beberapa tahapan utama, yaitu:

1. Pengumpulan Data Citra MRI

Penelitian ini menggunakan citra *Magnetic Resonance Imaging* (MRI) otak potongan aksial sebagai data utama untuk klasifikasi stadium penyakit Alzheimer. Penggunaan citra MRI didasarkan pada kemampuannya dalam merepresentasikan perubahan struktur otak yang berkaitan dengan perkembangan penyakit Alzheimer secara non-invasif [11], [12].

2. *Exploratory Data Analysis* (EDA)

Tahap *Exploratory Data Analysis* (EDA) dilakukan untuk memahami karakteristik dataset sebelum proses pemodelan. Analisis meliputi distribusi kelas, visualisasi sampel citra, distribusi intensitas piksel, dimensi spasial citra, serta korelasi fitur metadata. Hasil analisis digunakan untuk menentukan

kebutuhan prapengolahan dan pengambilan sampel data sehingga proses ekstraksi fitur dan pelatihan model dapat dilakukan secara lebih efisien.

3. Prapengolahan Citra (*Preprocessing*)

Tahap prapengolahan dilakukan untuk mempersiapkan data sebelum proses ekstraksi fitur. Proses ini meliputi pembagian data menjadi data pelatihan, validasi, dan pengujian, augmentasi citra pada data pelatihan, normalisasi nilai piksel pada jalur *deep learning*, serta penyesuaian ukuran citra sesuai kebutuhan masing-masing metode ekstraksi fitur [11].

4. Ekstraksi Fitur Tekstur (*Handcrafted Features*)

Ekstraksi fitur tekstur dilakukan menggunakan kombinasi *Gray Level Co-occurrence Matrix* (GLCM), *Histogram of Oriented Gradients* (HOG), dan *Local Binary Pattern* (LBP). Ketiga metode tersebut digunakan untuk memperoleh informasi tekstur, pola lokal, dan karakteristik gradien pada citra MRI sehingga mampu merepresentasikan struktur visual secara lebih komprehensif [10], [16].

5. Ekstraksi Fitur Mendalam (*Deep Feature Extraction*)

Ekstraksi fitur tingkat tinggi dilakukan menggunakan arsitektur EfficientNetB3 melalui pendekatan *transfer learning*. Metode ini digunakan untuk memperoleh representasi fitur abstrak yang lebih kompleks dari citra MRI tanpa perlu melatih model dari awal [14].

6. Pembentukan Fitur Hibrida

Fitur tekstur hasil ekstraksi GLCM, HOG, dan LBP digabungkan dengan *deep feature* yang diperoleh dari EfficientNetB3. Proses penggabungan ini menghasilkan representasi fitur hibrida yang diharapkan mampu menangkap informasi visual pada berbagai tingkat abstraksi sehingga meningkatkan kemampuan diskriminatif model [15].

7. Reduksi Dimensi

Untuk mengatasi tingginya dimensi fitur hasil penggabungan, dilakukan tiga skenario pengujian, yaitu tanpa reduksi dimensi sebagai *baseline*, reduksi dimensi menggunakan *Principal Component Analysis* (PCA) sebagai pendekatan linear [9], serta *Uniform Manifold Approximation and Projection* (UMAP) sebagai pendekatan non-linear [7].

8. Klasifikasi Menggunakan SVM

Fitur hasil dari masing-masing skenario digunakan sebagai masukan bagi algoritma *Support Vector Machine* (SVM). Algoritma ini dipilih karena memiliki kemampuan yang baik dalam menangani data berdimensi tinggi dan mampu menghasilkan batas keputusan yang optimal pada permasalahan klasifikasi multi-kelas [13].

9. Evaluasi Kinerja Model

Kinerja model dievaluasi menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-score*. Hasil evaluasi dari ketiga skenario dibandingkan untuk mengetahui pengaruh penggunaan PCA, UMAP, dan tanpa reduksi dimensi terhadap performa klasifikasi stadium penyakit Alzheimer [13], [15].

3. Hasil Analisis

Pada penelitian ini dilakukan serangkaian tahapan pengolahan citra MRI untuk mengklasifikasikan stadium penyakit Alzheimer menggunakan algoritma *Support Vector Machine* (SVM). Tahapan yang dilakukan meliputi *preprocessing* citra, ekstraksi fitur, reduksi dimensi, pelatihan model, dan evaluasi kinerja klasifikasi.

• Preprocessing Citra

Tahap preprocessing dilakukan untuk menghasilkan data yang siap digunakan pada proses ekstraksi fitur dan klasifikasi. Proses ini diimplementasikan menggunakan pustaka OpenCV dan Scikit-Learn. Tahapan preprocessing yang dilakukan meliputi:

1. *Resizing* (Penyeragaman Dimensi)

Citra pada dataset memiliki ukuran yang bervariasi, yaitu 180×180 piksel dan 200×190 piksel. Oleh karena itu, dilakukan penyeragaman ukuran citra agar proses ekstraksi fitur dapat dilakukan secara konsisten. Pada jalur ekstraksi fitur tradisional (GLCM, HOG, dan LBP), citra diubah menjadi ukuran 128×128 piksel, sedangkan pada jalur deep feature menggunakan EfficientNetB3 citra diubah menjadi ukuran 224×224 piksel sesuai dengan ukuran masukan model.

2. Normalisasi Nilai Piksel

Nilai intensitas piksel dinormalisasi ke rentang $[0,1]$ untuk mengurangi pengaruh perbedaan skala data dan membantu meningkatkan stabilitas proses pembelajaran model.

3. Pembagian Data dan Augmentasi

Dataset yang terdiri atas 6.000 citra dibagi menggunakan metode *stratified sampling* menjadi 70% data training, 15% data validation, dan 15% data testing. Augmentasi hanya diterapkan pada data training dengan operasi rotasi, pergeseran, pembalikan horizontal, dan perubahan tingkat kecerahan untuk meningkatkan variasi data tanpa mengubah karakteristik medis citra. Proses ini bertujuan untuk meningkatkan kemampuan generalisasi model terhadap data baru.

• Ekstraksi Fitur dan Reduksi Dimensi

Penelitian ini menggunakan pendekatan ekstraksi fitur hibrida yang menggabungkan fitur tradisional (*handcrafted features*) dan *deep features*.

1. Ekstraksi Fitur Tradisional (*Handcrafted Features*)

Fitur tradisional diperoleh melalui kombinasi tiga metode, yaitu Gray Level Co-occurrence Matrix (GLCM), Histogram of Oriented Gradients (HOG), dan Local Binary Pattern (LBP). GLCM digunakan untuk mengekstraksi karakteristik tekstur statistik berdasarkan hubungan antar piksel, LBP digunakan untuk menangkap pola tekstur lokal, sedangkan HOG digunakan untuk merepresentasikan struktur dan orientasi gradien pada citra. Kombinasi ketiga metode tersebut menghasilkan total 1.806 fitur.

2. Ekstraksi *Deep Feature*

Fitur tingkat tinggi diekstraksi menggunakan model EfficientNetB3 pra-latih (*pre-trained*) dengan lapisan Global Average Pooling sebagai keluaran fitur. Pendekatan ini menghasilkan representasi fitur yang mampu menangkap karakteristik spasial dan semantik dari citra MRI. Jumlah fitur yang diperoleh dari EfficientNetB3 adalah sebanyak 1.536 fitur.

Vektor fitur berdimensi tinggi yang dihasilkan dari kedua kelompok ekstraksi tersebut kemudian diproses menggunakan tiga skenario reduksi dimensi yang berbeda untuk dibandingkan efektivitasnya:

a. *Principal Component Analysis* (PCA)

PCA merupakan metode reduksi dimensi linear yang memproyeksikan data ke ruang baru berdasarkan variansi terbesar sehingga fitur yang bersifat redundan dapat dikurangi. Pada penelitian ini, PCA dikonfigurasi untuk mempertahankan 95% total variansi data, sehingga sebagian besar informasi penting dari fitur asli tetap terjaga meskipun jumlah dimensinya berkurang secara signifikan. Jumlah fitur setelah dilakukan PCA pada fitur tradisional menjadi 450 fitur dan pada deep feature menjadi 8 fitur.

b. *Uniform Manifold Approximation and Projection* (UMAP)

UMAP merupakan metode reduksi dimensi non-linear berbasis *manifold learning* yang dirancang untuk mempertahankan struktur lokal dan global data pada ruang berdimensi rendah. Pada penelitian ini, Umap diimplementasikan untuk menghasilkan representasi fitur yang lebih ringkas sehingga dapat mengurangi kompleksitas komputasi dan mempercepat proses pelatihan model. Pada penelitian ini, UMAP dikonfigurasi untuk mereduksi fitur data menjadi 50 komponen.

c. Tanpa Reduksi Dimensi

Pada skenario ini seluruh fitur asli digunakan tanpa dilakukan pengurangan dimensi sehingga dapat dijadikan sebagai model pembanding (*baseline*).

Fitur yang dihasilkan dari masing-masing skenario selanjutnya digunakan sebagai masukan bagi algoritma *Support Vector Machine* (SVM) untuk melakukan klasifikasi stadium penyakit Alzheimer. Kinerja model kemudian dievaluasi

menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score* untuk membandingkan efektivitas masing-masing metode reduksi dimensi yang digunakan.

• Hasil Model SVM

Setelah proses ekstraksi fitur dan reduksi dimensi selesai dilakukan, tahap selanjutnya adalah pelatihan model klasifikasi menggunakan algoritma Support Vector Machine (SVM). Implementasi model dilakukan dengan memanfaatkan kelas Support Vector Classification (SVC) dari pustaka Scikit-Learn. Pada penelitian ini digunakan fungsi kernel Radial Basis Function (RBF) dengan parameter $C = 10$ dan $\gamma = \text{scale}$.

Proses pelatihan dan pengujian model dilakukan pada enam skenario yang dibedakan berdasarkan kombinasi metode ekstraksi fitur dan teknik reduksi dimensi yang digunakan. Kombinasi skenario pengujian tersebut ditunjukkan pada Tabel 3.

Tabel 3. Kombinasi Metode Ekstraksi Fitur dan Reduksi Dimensi

NO	Ekstraksi Fitur	Reduksi Dimensi
1	GLCM + HOG + LBP	Tanpa Reduksi Dimensi
2	GLCM + HOG + LBP	PCA
3	GLCM + HOG + LBP	UMAP
4	EfficientNetB3	Tanpa Reduksi Dimensi
5	EfficientNetB3	PCA
6	EfficientNetB3	UMAP

Pada setiap skenario, model SVM dilatih menggunakan data training dan selanjutnya digunakan untuk melakukan prediksi kelas pada data testing. Kinerja model kemudian dievaluasi menggunakan beberapa metrik klasifikasi, yaitu *accuracy*, *precision*, *recall*, dan *F1-score*. Selain itu, *confusion matrix* digunakan untuk menganalisis kemampuan model dalam mengklasifikasikan setiap kelas stadium penyakit Alzheimer serta mengidentifikasi pola kesalahan klasifikasi yang terjadi.

• Evaluasi dan Perbandingan Kinerja Model

Kinerja model *Support Vector Machine* (SVM) dievaluasi menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Perbandingan performa dari enam skenario pengujian disajikan pada Tabel 4.

Tabel 4. Hasil Rekapitulasi Evaluasi Model Klasifikasi Alzheimer

Skenario Model	<i>Accuracy</i> (%)	<i>Precision</i> (%)	<i>Recall</i> (%)	<i>F1-score</i> (%)
Tradisional Tanpa DR	67.00	73.67	67.00	66.73
Tradisional PCA	76.33	73.46	67.33	67.06
Tradisional UMAP	31.78	32.69	31.78	27.78
EfficientNetB3 Tanpa DR	64.56	64.39	64.56	63.95

EfficientNetB3 PCA	39.67	38.11	39.67	37.25
EfficientNetB3 UMAP	34.56	35.47	34.56	32.18

Berdasarkan tabel 4, kombinasi fitur tradisional yang terdiri atas GLCM, HOG, dan LBP dengan reduksi dimensi menggunakan PCA menghasilkan performa terbaik dengan nilai akurasi sebesar 67,33%, *precision* sebesar 73,46%, *recall* sebesar 67,33%, dan *F1-score* sebesar 67,06%. Hasil tersebut menunjukkan bahwa PCA mampu mereduksi dimensi fitur tanpa menghilangkan sebagian besar informasi penting yang diperlukan oleh SVM dalam membedakan stadium penyakit Alzheimer.


Sementara itu, penggunaan fitur tradisional tanpa reduksi dimensi menghasilkan performa yang relatif sebanding dengan akurasi sebesar 67,00%. Hal ini menunjukkan bahwa fitur tekstur yang diekstraksi menggunakan kombinasi GLCM, HOG, dan LBP telah mampu merepresentasikan karakteristik citra MRI dengan baik sehingga tetap memberikan hasil klasifikasi yang tinggi meskipun tanpa proses reduksi dimensi.

Pada fitur berbasis *deep learning*, kombinasi EfficientNetB3 tanpa reduksi dimensi menghasilkan akurasi sebesar 64,56%. Namun, penerapan PCA maupun UMAP pada *deep feature* menyebabkan penurunan performa yang cukup signifikan. EfficientNetB3 dengan PCA hanya menghasilkan akurasi sebesar 39,67%, sedangkan EfficientNetB3 dengan UMAP memperoleh akurasi sebesar 34,56%. Hasil tersebut mengindikasikan bahwa proses reduksi dimensi menyebabkan sebagian informasi diskriminatif yang terkandung dalam *deep feature* tidak dapat dipertahankan secara optimal.

Secara umum, metode UMAP menghasilkan performa terendah pada kedua jenis fitur yang digunakan. Kombinasi fitur tradisional dengan UMAP hanya menghasilkan akurasi sebesar 31,78%, sedangkan kombinasi EfficientNetB3 dengan UMAP menghasilkan akurasi sebesar 34,56%. Hal ini menunjukkan bahwa representasi fitur hasil UMAP kurang mampu mempertahankan karakteristik pembeda antar kelas pada dataset yang digunakan.


• Analisis Kesalahan Klasifikasi Berdasarkan *Confusion Matrix*

Analisis *confusion matrix* dilakukan untuk mengetahui kemampuan model dalam mengklasifikasikan setiap kelas stadium penyakit Alzheimer serta mengidentifikasi pola kesalahan prediksi yang terjadi pada masing-masing skenario. Berdasarkan hasil evaluasi, model dengan fitur tradisional yang dikombinasikan dengan *Principal Component Analysis* (PCA) menghasilkan performa terbaik dengan akurasi sebesar 67,33%, diikuti oleh model fitur tradisional tanpa reduksi dimensi dengan akurasi sebesar 67,00%.




Gambar 8. *Confusion Matrix* Jalur Tradisional Tanpa Reduksi Dimensi (kiri) dan Tradisional-PCA (kanan)

Berdasarkan *confusion matrix* pada skenario fitur tradisional tanpa reduksi dimensi dan fitur tradisional dengan PCA yang ditunjukkan pada Gambar 8, kedua model memperlihatkan pola klasifikasi yang relatif serupa. Kelas *Moderate Demented* merupakan kelas yang paling mudah dikenali, dengan sebanyak 222 dari 225 sampel berhasil diklasifikasikan secara benar. Sebaliknya, kesalahan klasifikasi masih banyak terjadi pada kelas *Mild Demented*, *Non-Demented*, dan *Very Mild Demented*. Sebagai contoh, pada skenario tanpa reduksi dimensi terdapat sejumlah citra *Mild Demented* dan *Non-Demented* yang diprediksi sebagai *Very Mild Demented*. Kondisi tersebut menunjukkan adanya kemiripan karakteristik citra pada stadium awal Alzheimer sehingga batas pemisah antar kelas menjadi lebih sulit dibentuk.




Gambar 9. *Confusion Matrix* Jalur Tradisional-UMAP

Pada skenario fitur tradisional dengan UMAP yang ditunjukkan pada gambar 9, sebagian besar sampel dari berbagai kelas cenderung diprediksi ke kelas *Moderate Demented*. Sebagai contoh, sebanyak 142 sampel *Mild Demented* dan 133 sampel *Very Mild Demented* salah diklasifikasikan sebagai *Moderate Demented*. Hasil tersebut menunjukkan bahwa representasi fitur hasil UMAP kurang mampu mempertahankan informasi pembeda antar kelas secara optimal.



Gambar 10. *Confusion Matrix* Jalur EfficientNetB3 Tanpa Reduksi Dimensi

Pada skenario EfficientNetB3 tanpa reduksi dimensi, model memperoleh akurasi sebesar 64,56% dan hasil *confusion matrix* pada gambar 10 masih mampu mengenali kelas *Moderate Demented* dengan baik melalui 220 prediksi benar dari 225 sampel. Selain itu, kelas *Mild Demented* memiliki 139 prediksi benar, lebih tinggi dibandingkan pendekatan fitur tradisional. Namun demikian, kesalahan klasifikasi masih cukup besar pada kelas *Non-Demented*, di mana 79 sampel diprediksi sebagai *Very Mild Demented*, serta pada kelas *Very Mild Demented* yang hanya menghasilkan 112 prediksi benar. Hasil tersebut mengindikasikan bahwa *deep feature* dari EfficientNetB3 mampu menangkap karakteristik global citra, tetapi masih mengalami kesulitan dalam membedakan stadium yang memiliki kemiripan visual tinggi.



Gambar 11. *Confusion Matrix* Jalur EfficientNetB3-PCA (kiri) dan EfficientNetB3-UMAP (kanan)

Ketika dilakukan reduksi dimensi menggunakan *Principal Component Analysis* (PCA) pada fitur EfficientNetB3, performa model mengalami penurunan yang cukup signifikan dengan akurasi sebesar 39,67%. Berdasarkan gambar 11, jumlah prediksi benar pada kelas *Mild Demented* hanya mencapai 38 sampel, sementara 95 sampel lainnya salah diklasifikasikan sebagai *Moderate Demented*. Selain itu, jumlah prediksi benar pada kelas *Moderate Demented* juga menurun menjadi 150 sampel, sedangkan kelas *Very Mild Demented* hanya berhasil diprediksi dengan benar sebanyak 54 sampel.

Penurunan performa ini mengindikasikan bahwa proses reduksi dimensi menggunakan PCA menyebabkan sebagian informasi penting yang terkandung dalam *deep feature* tidak dapat dipertahankan secara optimal. Kondisi yang lebih buruk terlihat pada kombinasi EfficientNetB3 dengan UMAP, yang hanya memperoleh akurasi sebesar 34,56%. *Confusion matrix* menunjukkan bahwa model memiliki kecenderungan mengelompokkan sebagian besar sampel ke dalam kelas *Moderate Demented*, sehingga terjadi salah klasifikasi yang cukup besar, yaitu 135 sampel *Mild Demented*, 71 sampel *Non-Demented*, dan 107 sampel *Very Mild Demented* diprediksi sebagai *Moderate Demented*. Akibatnya, jumlah prediksi benar pada kelas *Mild Demented*, *Non-Demented*, dan *Very Mild Demented* masing-masing hanya mencapai 42, 77, dan 35 sampel.

Temuan ini menunjukkan bahwa baik PCA maupun UMAP belum mampu mempertahankan karakteristik diskriminatif dari *deep feature* EfficientNetB3 secara optimal, sehingga kemampuan SVM dalam membedakan setiap stadium penyakit Alzheimer mengalami penurunan yang cukup signifikan.

Secara keseluruhan, kelas *Moderate Demented* merupakan kelas yang paling mudah dikenali pada seluruh skenario pengujian. Sebaliknya, kelas *Mild Demented*, *Very Mild Demented*, dan *Non-Demented* masih sering mengalami salah klasifikasi karena memiliki karakteristik citra yang relatif mirip. Selain itu, fitur tradisional yang diperoleh dari kombinasi GLCM, HOG, dan LBP memberikan performa yang lebih baik dibandingkan *deep feature* EfficientNetB3 pada penelitian ini. Di antara seluruh skenario yang diuji, kombinasi fitur tradisional dengan reduksi dimensi PCA memberikan performa terbaik dengan akurasi sebesar 67,33%, sehingga dapat dianggap sebagai konfigurasi yang paling efektif untuk klasifikasi stadium penyakit Alzheimer pada dataset yang digunakan.

● Analisis Pengaruh Metode Reduksi Dimensi terhadap Kinerja SVM

Penelitian ini bertujuan untuk menganalisis pengaruh metode reduksi dimensi terhadap performa klasifikasi stadium penyakit Alzheimer menggunakan algoritma *Support Vector Machine* (SVM). Tiga skenario yang dibandingkan meliputi tanpa reduksi dimensi, penggunaan *Principal Component Analysis* (PCA), dan *Uniform Manifold Approximation and Projection* (UMAP). Pengujian dilakukan pada dua jenis representasi fitur, yaitu fitur tradisional yang merupakan kombinasi *Gray Level Co-occurrence Matrix* (GLCM), *Histogram of Oriented Gradients* (HOG), dan *Local Binary Pattern* (LBP), serta *deep feature* yang diekstraksi menggunakan EfficientNetB3.

1. Pengaruh PCA

PCA digunakan untuk mereduksi dimensi data dengan mempertahankan 95% variansi dari data asli. Pada fitur tradisional, penerapan PCA menghasilkan akurasi sebesar 67,33%, yang hampir sama dengan skenario tanpa reduksi dimensi sebesar 67,00%. Hasil ini menunjukkan bahwa PCA mampu mengurangi jumlah fitur secara signifikan tanpa menyebabkan kehilangan informasi yang berarti. Pola *confusion matrix* juga menunjukkan distribusi prediksi yang hampir identik dengan fitur

tradisional tanpa reduksi dimensi, sehingga dapat disimpulkan bahwa sebagian besar informasi tekstur yang relevan masih berhasil dipertahankan oleh PCA.

Namun, hasil yang berbeda diperoleh pada fitur EfficientNetB3. Akurasi model menurun dari 64,56% pada fitur asli menjadi 39,67% setelah diterapkan PCA. Penurunan ini menunjukkan bahwa proses reduksi dimensi menghilangkan sebagian informasi penting yang terkandung dalam deep feature sehingga kemampuan SVM dalam membedakan kelas menjadi berkurang. Dengan demikian, efektivitas PCA sangat bergantung pada karakteristik fitur yang digunakan.

2. Pengaruh UMAP

UMAP digunakan sebagai metode reduksi dimensi non-linear dengan jumlah komponen yang lebih rendah dibandingkan dimensi asli data. Berdasarkan hasil pengujian, UMAP menghasilkan penurunan performa yang signifikan pada kedua jenis fitur. Pada fitur tradisional, akurasi turun menjadi 31,78%, sedangkan pada fitur EfficientNetB3 akurasi hanya mencapai 34,56%. Hasil *confusion matrix* menunjukkan bahwa model cenderung memprediksi sebagian besar sampel ke kelas *Moderate Demented* sehingga distribusi prediksi menjadi tidak seimbang. Fenomena ini menunjukkan bahwa representasi fitur yang dihasilkan oleh UMAP belum mampu mempertahankan informasi diskriminatif yang diperlukan oleh SVM untuk membentuk *hyperplane* pemisah yang optimal. Walaupun UMAP dirancang untuk mempertahankan struktur non-linear data, pendekatan tersebut kurang sesuai untuk kebutuhan klasifikasi stadium Alzheimer pada dataset yang digunakan dalam penelitian ini.

3. Pengaruh Tanpa Reduksi Dimensi

Skenario tanpa reduksi dimensi memberikan performa terbaik pada penelitian ini. Pada fitur tradisional, model memperoleh akurasi sebesar 67,00%, precision sebesar 73,67%, recall sebesar 67,00%, dan F1-score sebesar 66,73%. Hasil *confusion matrix* menunjukkan bahwa kelas *Moderate Demented* berhasil dikenali dengan sangat baik, sedangkan kesalahan klasifikasi masih banyak terjadi antara kelas *Mild Demented*, *Non-Demented*, dan *Very Mild Demented* yang memiliki karakteristik citra relatif mirip. Pada fitur EfficientNetB3 tanpa reduksi dimensi, model memperoleh akurasi sebesar 64,56%. Meskipun sedikit lebih rendah dibandingkan fitur tradisional, *confusion matrix* menunjukkan bahwa EfficientNetB3 mampu mengenali kelas Mild Demented dan Non-Demented dengan jumlah prediksi benar yang lebih tinggi. Namun demikian, performa pada kelas *Very Mild Demented* masih lebih rendah dibandingkan fitur tradisional sehingga akurasi keseluruhan tetap lebih kecil.

● Kesimpulan Hasil Evaluasi Model

Berdasarkan seluruh hasil eksperimen, metode reduksi dimensi memberikan pengaruh yang berbeda terhadap masing-masing jenis fitur. PCA terbukti mampu mempertahankan performa klasifikasi pada fitur tradisional meskipun jumlah dimensi berkurang secara signifikan. Sebaliknya, PCA kurang efektif pada fitur EfficientNetB3 karena menyebabkan hilangnya informasi penting yang dibutuhkan untuk proses klasifikasi. UMAP menghasilkan performa terendah pada kedua jenis

fitur sehingga belum mampu menghasilkan representasi fitur yang optimal untuk klasifikasi menggunakan SVM.

Secara keseluruhan, kombinasi fitur tradisional tanpa reduksi dimensi memberikan performa terbaik dan setabil dalam semua hasil metrik evaluasi dengan akurasi sebesar 67,00%, precision sebesar 73,67%, recall sebesar 67,00%, dan F1-score sebesar 66,73%. Hasil ini menunjukkan bahwa informasi tekstur yang diekstraksi menggunakan GLCM, HOG, dan LBP masih sangat relevan dalam membedakan stadium penyakit Alzheimer pada citra MRI. Oleh karena itu, pada dataset yang digunakan dalam penelitian ini, penerapan reduksi dimensi tidak memberikan peningkatan performa klasifikasi dan bahkan dapat menyebabkan penurunan akurasi apabila informasi penting dalam data ikut tereduksi.

4. Kesimpulan dan Saran

- **Kesimpulan**

Berdasarkan hasil penelitian yang telah dilakukan, algoritma *Support Vector Machine* (SVM) mampu mengklasifikasikan stadium penyakit Alzheimer menggunakan fitur yang diekstraksi dari citra MRI. Hasil pengujian menunjukkan bahwa fitur tradisional yang diperoleh dari kombinasi *Gray Level Co-occurrence Matrix* (GLCM), *Histogram of Oriented Gradients* (HOG), dan *Local Binary Pattern* (LBP) memberikan performa yang lebih baik dibandingkan *deep feature* yang diekstraksi menggunakan EfficientNetB3. Temuan ini menunjukkan bahwa informasi tekstur yang terkandung dalam citra MRI masih sangat efektif untuk membedakan karakteristik antar stadium penyakit Alzheimer.

Analisis pengaruh reduksi dimensi menunjukkan bahwa *Principal Component Analysis* (PCA) mampu mempertahankan performa klasifikasi pada fitur tradisional meskipun jumlah dimensi berkurang secara signifikan. Namun, peningkatan performa yang diperoleh relatif kecil dibandingkan penggunaan fitur asli tanpa reduksi dimensi. Sebaliknya, penerapan PCA maupun *Uniform Manifold Approximation and Projection* (UMAP) pada fitur EfficientNetB3 menyebabkan penurunan performa, yang mengindikasikan adanya kehilangan informasi penting selama proses reduksi dimensi. Selain itu, UMAP menghasilkan performa terendah pada kedua jenis fitur yang digunakan.

Secara keseluruhan, kombinasi fitur tradisional tanpa reduksi dimensi menunjukkan performa yang paling stabil berdasarkan seluruh metrik evaluasi yang digunakan, dengan *accuracy* sebesar 67,00%, *precision* sebesar 73,67%, *recall* sebesar 67,00%, dan *F1-score* sebesar 66,73%. Oleh karena itu, dapat disimpulkan bahwa penerapan reduksi dimensi pada penelitian ini belum memberikan peningkatan performa klasifikasi yang signifikan, sehingga penggunaan fitur tradisional tanpa reduksi dimensi menjadi pendekatan yang paling efektif untuk klasifikasi stadium penyakit Alzheimer pada dataset yang digunakan.

• Saran

Berdasarkan hasil penelitian yang telah diperoleh, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya:

1. Mencoba metode reduksi dimensi lain seperti *Linear Discriminant Analysis* (LDA), *Autoencoder*, *Variational Autoencoder* (VAE), atau t-SNE untuk membandingkan efektivitasnya terhadap PCA dan UMAP.
2. Melakukan optimasi parameter pada metode PCA, UMAP, maupun SVM untuk memperoleh kombinasi parameter yang menghasilkan performa klasifikasi terbaik.
3. Mengembangkan ekstraksi fitur menggunakan arsitektur *deep learning* yang lebih modern, seperti EfficientNetV2, DenseNet, ConvNeXt, atau *Vision Transformer* (ViT).
4. Membandingkan performa SVM dengan algoritma klasifikasi lain seperti *Random Forest*, XGBoost, LightGBM, dan *K-Nearest Neighbor* (KNN) untuk memperoleh model yang paling optimal.

Daftar Pustaka

Sitasi disusun dan ditulis berdasarkan sistem nomor sesuai dengan urutan pengutipan, mengikuti format IEEE. Hanya pustaka yang disitasi pada usulan penelitian yang dicantumkan dalam Daftar Pustaka. Pustaka yang disitasi maksimal 10 tahun terakhir sebanyak minimal 10 pustaka.

- [1] M. Živanović, A. A. Trenkić, V. Milošević, D. Stojanov, M. Mišić, M. Radovanović, and V. Radovanović, "The role of magnetic resonance imaging in the diagnosis and prognosis of dementia," *Biomolecules & Biomedicine*, vol. 23, no. 2, pp. 209–224, 2022.
- [2] A. Sharma, S. Kaur, N. Memon, A. J. Fathima, S. Ray, and M. W. Bhatt, "Alzheimer's patients detection using support vector machine (SVM) with quantitative analysis," *Neuroscience Informatics*, vol. 1, no. 1, p. 100012, 2021.
- [3] D. Sherzai and A. Sherzai, "Preventing Alzheimer's: Our most urgent health care priority," *American Journal of Lifestyle Medicine*, vol. 13, no. 5, pp. 451–461, Sep.–Oct. 2019.
- [4] National Institute on Aging, "What happens to the brain in Alzheimer's disease," U.S. Department of Health and Human Services, 2024.
- [5] Z. Yu, A. Mulholland, T. Huang, and Q. Liu, "Multimodal AI for Alzheimer Disease Diagnosis: Systematic Review of Datasets, Models, and Modalities," *Journal of Medical Internet Research*, vol. 28, e85414, 2026.
- [6] V. Sarveshwaran, A. Sevugan, and I. T. J. Swamidason, "A Review of Dimensionality Reduction Techniques for Efficient Computation," *Procedia Computer Science*, vol. 165, pp. 104–111, 2019.
- [7] L. McInnes, J. Healy, and J. Melville, "UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction," arXiv preprint arXiv:1802.03426, 2020.
- [8] A. Singhal, "Alzheimer's Disease Multiclass Images Dataset (Equal and Augmented)," *Kaggle*, 2024. [Online]. Available: <https://www.kaggle.com/datasets/aryansinghal10/alzheimers-multiclass-dataset-equal-and-augmented>.
- [9] M. Amini, H. S. Rad, and M. R. N. Afshar, "A machine learning approach with optimized feature selection for medical classification tasks," *International Journal of Medical Informatics*, vol. 14, no. 2, pp. 112–121, 2021.

- [10] S. Ranjan, A. K. Singh, and B. Kumar, "Extraction of medical texture features using local texton structures on diagnostic scan images," *Biomedical Signal Processing and Control*, vol. 65, p. 102341, 2021.
- [11] M. Afifi, "Evaluation of advanced image preprocessing, resizing, and contrast enhancement techniques for brain MRI scans," *Journal of Digital Imaging*, vol. 34, no. 4, pp. 885–897, 2021.
- [12] A. R. Al-shamasneh, U. A. R. S. S. Ahmad, and W. H. F. W. Ismail, "Automated cluster-based hippocampus segmentation framework from MRI for Alzheimer's disease diagnosis," *Brain Informatics*, vol. 8, no. 1, p. 14, 2021.
- [13] S. Venkatesan and S. Sivasubramanian, "An efficient neurodegenerative disease classification schema based on support vector machines and clustering paradigms," *Journal of Clinical Neuroscience*, vol. 89, pp. 245–254, 2021.
- [14] P. Murugan, S. S. S. J. Ahmed, and S. Kumar, "Transfer learning and deep convolutional neural networks for automated Alzheimer's disease detection from brain MRI," *Computers in Biology and Medicine*, vol. 138, p. 104845, 2021.
- [15] L. Saba, M. F. A. El-Khamy, and G. M. S. El-Sallam, "A hybrid framework combining handcrafted and deep features for Alzheimer's disease multiclass classification via brain MRI," *Computers in Biology and Medicine*, vol. 141, p. 105123, 2022.
- [16] U. Garg, M. Shabaz, and K. Mahajan, "Early detection of Alzheimer's disease using GLCM texture features and machine learning algorithms," *Wireless Communications and Mobile Computing*, vol. 2022, 2022.

Lampiran

Lampiran 1. Kode lengkap terkait project dapat diakses melalui tautan berikut ini: :
<https://github.com/christine2646/UAS-PENGOLAHAN-CITRA-DIGITAL-KELOMPOK-2>